

Kepuasan Mahasiswa IBIKKG terhadap Layanan Akademik Menggunakan Algoritma Naïve Bayes dan K-NN

Charlie Parulianta ⁽¹⁾, Marco Marcheleno ⁽²⁾, Jason Ronaldo Wijaya ⁽³⁾, Tundo ⁽⁴⁾
Program Studi Sistem Informasi, Institut Bisnis dan Informatika Kwik Kian Gie, Indonesia
Email: 45239046@student.kwikiangie.ac.id

* Penulis korespondensi.

Artikel ini diajukan xx xxxx 2025, direvisi xx xxxx 2025, diterima xx xxxx 2025, dan dipublikasikan xx xxxx 2025.

Abstract

Academic service quality is an important factor in supporting student satisfaction in higher education institutions. This study aims to analyze the level of student satisfaction at the Kwik Kian Gie Institute of Business and Informatics (IBIKKG) with respect to the academic services provided, as well as to identify service aspects that require improvement. The research employs a descriptive quantitative approach, with data collected through an online questionnaire using Google Forms. The data were analyzed using the Naïve Bayes and K-Nearest Neighbor (K-NN) algorithms to classify student satisfaction levels into three categories: dissatisfied, moderately satisfied, and highly satisfied. The results indicate that the majority of students are moderately satisfied with the academic services, particularly in terms of administrative staff services and the clarity of academic information. However, dissatisfaction was identified regarding service responsiveness and the academic communication system. These findings are expected to provide valuable input for campus management in improving the quality of academic services on a continuous basis. Furthermore, the applied algorithms were able to produce predictive classification results with a prediction consistency rate of 76.67%.

Keywords: Student Satisfaction; Academic Services; Text Mining; IBI Kwik Kian Gie.

Abstrak

Kualitas layanan akademik merupakan faktor penting dalam mendukung kepuasan mahasiswa terhadap institusi pendidikan tinggi. Penelitian ini bertujuan untuk menganalisis tingkat kepuasan mahasiswa Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG) terhadap layanan akademik yang diberikan, serta mengidentifikasi aspek-aspek layanan yang perlu ditingkatkan. Metode penelitian yang digunakan adalah pendekatan kuantitatif deskriptif dengan pengumpulan data melalui kuesioner online menggunakan Google Form. Data dianalisis menggunakan algoritma Naïve Bayes & K-NN untuk mengelompokkan tingkat kepuasan mahasiswa menjadi kategori tidak puas, cukup puas dan sangat puas. Hasil penelitian menunjukkan bahwa mayoritas mahasiswa memiliki penilaian cukup puas terhadap layanan akademik, terutama pada aspek pelayanan staf administrasi dan kejelasan informasi akademik. Namun, ditemukan pula ketidakpuasan terkait responsivitas pelayanan dan sistem komunikasi akademik. Temuan ini diharapkan dapat menjadi masukan bagi pihak manajemen kampus untuk meningkatkan mutu layanan akademik secara berkelanjutan. Sementara dari segi algoritma yang digunakan tersebut mampu memberikan hasil klasifikasi prediksi dengan Tingkat Konsistensi Prediksi sebesar 76,67%.

Kata Kunci: Kepuasan Mahasiswa; Layanan Akademik; Text Mining; IBI Kwik Kian Gie.



1. PENDAHULUAN

Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG) merupakan salah satu perguruan tinggi swasta di Jakarta yang berkomitmen dalam pengembangan sumber daya manusia unggul di bidang bisnis, manajemen, dan teknologi informasi melalui penyelenggaraan layanan akademik yang terintegrasi. Kualitas layanan akademik memiliki peran penting dalam membentuk persepsi dan kepuasan mahasiswa, khususnya pada aspek pelayanan administratif, kejelasan informasi akademik, serta dukungan sistem informasi akademik berbasis teknologi. Sejalan dengan hal tersebut, IBIKKG terus melakukan peningkatan mutu layanan akademik kepada mahasiswa, baik dalam aspek administratif, komunikasi akademik, maupun dukungan teknologi pembelajaran melalui Student Service System (SSS) dan Learning Management System (LMS). Peningkatan kualitas layanan akademik ini diharapkan mampu menciptakan pengalaman belajar yang positif sehingga berdampak pada tingkat kepuasan, motivasi, dan loyalitas mahasiswa terhadap institusi (Attamimi et al., 2022).

Meskipun berbagai inovasi telah dilakukan, masih ditemukan sejumlah tantangan yang memengaruhi persepsi kepuasan mahasiswa terhadap layanan akademik. Permasalahan seperti lambatnya proses administrasi, keterlambatan penyampaian informasi akademik, serta kurang responsifnya komunikasi antara pihak akademik dan mahasiswa menunjukkan bahwa efektivitas layanan yang tersedia belum sepenuhnya optimal. Kondisi ini sejalan dengan temuan penelitian yang menegaskan bahwa komunikasi digital yang tidak efektif dan rendahnya responsivitas layanan dapat menurunkan tingkat kepuasan mahasiswa, meskipun institusi telah mengadopsi sistem layanan berbasis teknologi (Anhikmah, 2025). Hal ini mengindikasikan bahwa implementasi sistem akademik terkomputerisasi perlu diimbangi dengan evaluasi berkelanjutan terhadap kualitas layanan dan komunikasi agar mampu memenuhi ekspektasi mahasiswa secara menyeluruh.

Permasalahan utama yang dihadapi adalah belum adanya pengukuran berbasis data yang mampu menggambarkan tingkat kepuasan mahasiswa terhadap layanan akademik IBIKKG secara objektif dan terukur. Selama ini, evaluasi kepuasan mahasiswa umumnya dilakukan melalui survei kualitatif atau umpan balik umum tanpa dukungan analisis kuantitatif yang sistematis dan prediktif. Padahal, dalam penelitian kuantitatif, metode survei dengan instrumen terstruktur sangat relevan digunakan untuk mengukur persepsi responden secara numerik sehingga hasilnya dapat dianalisis secara statistik dan dijadikan dasar pengambilan keputusan yang lebih akurat (Kahar Muhammad Syahrul, Anwar Zakiyah Anwar Zakiyah, 2023). Oleh karena itu, diperlukan pendekatan berbasis data mining yang mampu mengolah data kuantitatif hasil kuesioner secara sistematis guna menganalisis dan memprediksi tingkat kepuasan mahasiswa sebagai dasar pendukung keputusan strategis dalam peningkatan layanan akademik.

Sebagai solusi, penelitian ini menerapkan kombinasi algoritma **Naïve Bayes Classifier** dan **K-Nearest Neighbor (K-NN)** untuk mengklasifikasikan tingkat kepuasan mahasiswa berdasarkan hasil kuesioner yang mencakup sembilan aspek layanan akademik, seperti kejelasan informasi, keramahan petugas, kecepatan administrasi, dan ketersediaan sarana pembelajaran. Pemilihan kedua algoritma tersebut didasarkan pada karakteristiknya yang efektif dalam menangani data klasifikasi berbasis numerik serta kemampuannya menghasilkan tingkat akurasi yang tinggi pada berbagai studi perbandingan algoritma klasifikasi (Kenia et al., 2023). Secara alur kerja (*workflow*), data kuesioner terlebih dahulu melalui proses pra-pemrosesan berupa pembersihan data (*data cleaning*), konversi skala Likert menjadi nilai numerik, normalisasi, serta pembagian data menjadi data latih dan data uji. Selanjutnya, algoritma Naïve Bayes digunakan untuk menghitung probabilitas setiap kategori kepuasan berdasarkan distribusi fitur, sedangkan K-NN mengelompokkan mahasiswa berdasarkan tingkat kemiripan pola jawaban menggunakan jarak Euclidean.

Hasil dari penerapan algoritma Naïve Bayes dan K-Nearest Neighbor selanjutnya dibandingkan berdasarkan tingkat akurasi, sehingga dapat diketahui metode yang paling efektif dalam memprediksi tingkat kepuasan mahasiswa terhadap layanan akademik. Perbandingan kinerja



model klasifikasi ini penting karena hasil analisis tidak hanya menggambarkan kondisi kepuasan mahasiswa secara deskriptif, tetapi juga menghasilkan model prediktif yang bersifat objektif dan terukur. Pendekatan klasifikasi berbasis data mining terbukti mampu mengidentifikasi pola kepuasan mahasiswa secara lebih mendalam serta memberikan tingkat akurasi yang tinggi dalam pengujian data, sehingga dapat dijadikan dasar yang kuat dalam mendukung pengambilan keputusan strategis institusi pendidikan tinggi (Natalia Nurtiani & Adi Saputra, 2024). Model prediktif yang dihasilkan diharapkan dapat dimanfaatkan oleh pihak kampus sebagai alat evaluasi berkelanjutan untuk meningkatkan kualitas layanan akademik di masa mendatang.

Beberapa penelitian terdahulu juga telah mengkaji topik serupa mengenai pengukuran kepuasan pengguna terhadap layanan berbasis sistem informasi dan akademik. **Penelitian pertama** oleh yang berjudul "*Analisa Kepuasan Mahasiswa terhadap E-Learning Menggunakan Algoritma Support Vector Machine*" (Ima. Hendro, 2022) menekankan pada penerapan algoritma *machine learning* untuk mengklasifikasikan tingkat kepuasan mahasiswa terhadap sistem *e-learning*. Namun, penelitian tersebut hanya berfokus pada aspek teknologi pembelajaran *online* dan tidak meninjau dimensi layanan akademik secara menyeluruh. **Penelitian kedua** dilakukan oleh (Butarbutar et al., 2021) dalam studi berjudul "*Analisa Kepuasan Mahasiswa terhadap Pelayanan Akademik dengan Pendekatan Metode SERVQUAL dan QFD*", yang menggunakan pendekatan *Service Quality* untuk mengidentifikasi kesenjangan antara harapan dan persepsi mahasiswa. Meskipun memberikan pemetaan kualitas layanan, penelitian tersebut belum mengintegrasikan pendekatan klasifikasi berbasis *data mining* untuk menghasilkan model prediktif. **Penelitian ketiga** oleh (Fauzi et al., 2022) dengan judul "*Mengukur Tingkat Kepuasan Pengguna Aplikasi Kearsipan Menggunakan System Usability Scale dan PIECES Framework*" berfokus pada evaluasi kepuasan pengguna aplikasi melalui model usability, namun konteksnya terbatas pada perangkat lunak arsip, bukan layanan akademik institusi.

Beberapa penelitian terdahulu juga telah mengkaji pengukuran tingkat kepuasan mahasiswa terhadap layanan akademik dengan pendekatan data mining dan algoritma klasifikasi. Penelitian yang dilakukan oleh (Dewi Antika, Syaiful Zuhri Harahap, Rahma Muti Ah, 2025) menerapkan metode Naïve Bayes dan Support Vector Machine (SVM) untuk mengklasifikasikan tingkat kepuasan mahasiswa terhadap pelayanan akademik berbasis data kuesioner. Hasil penelitian tersebut menunjukkan bahwa pendekatan klasifikasi mampu menghasilkan tingkat akurasi yang tinggi dan memberikan gambaran prediktif mengenai kepuasan mahasiswa secara objektif, sehingga dapat dimanfaatkan sebagai dasar pengambilan keputusan dalam peningkatan kualitas layanan akademik. Namun demikian, penelitian tersebut berfokus pada perbandingan Naïve Bayes dan SVM dalam satu konteks studi kasus tertentu, sehingga masih terbuka peluang penelitian lanjutan dengan mengombinasikan atau membandingkan algoritma lain guna memperoleh model klasifikasi yang lebih optimal dan sesuai dengan karakteristik data institusi pendidikan yang berbeda.


2. METODE PENELITIAN

Metode penelitian ini disusun secara sistematis untuk menganalisis tingkat kepuasan mahasiswa terhadap layanan akademik di Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG). Penelitian ini menggunakan pendekatan data mining dengan metode klasifikasi, yaitu Naïve Bayes dan K-Nearest Neighbor (K-NN). Pendekatan data mining dipilih karena mampu mengekstraksi pola dan pengetahuan dari data kuesioner dalam jumlah besar secara efektif, sebagaimana diterapkan pada penelitian kepuasan mahasiswa di Universitas Maritim AMNI yang menunjukkan bahwa proses transformasi, preprocessing, dan pemodelan sangat menentukan kualitas hasil analisis kepuasan (Ima. Hendro, 2022).

Pemilihan algoritma Naïve Bayes dan K-NN bertujuan untuk membandingkan performa **model probabilistik** dan **model berbasis jarak** dalam proses klasifikasi. Kombinasi kedua algoritma ini banyak digunakan pada penelitian analisis sentimen dan kepuasan karena mampu memberikan perbandingan kinerja yang jelas dari sisi akurasi, presisi, dan recall (Saurina et al., 2022). Alur penelitian divisualisasikan dalam bentuk flowchart pada Gambar 1 yang mencakup tahapan pengumpulan data, preprocessing data, pembangunan model klasifikasi, evaluasi model, dan



penarikan kesimpulan. Setiap tahapan disusun secara berurutan agar proses analisis berjalan terstruktur dan dapat dipertanggungjawabkan secara ilmiah



Gambar 1. Model Metode Penelitian

2.1 PENGUMPULAN DATA

Pengumpulan data dalam penelitian ini dilakukan melalui penyebaran kuesioner kepada mahasiswa Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG) sebagai instrumen utama untuk memperoleh data persepsi responden secara terstruktur. Pendekatan kuesioner dipilih karena efektif dalam menghimpun data kuantitatif yang merepresentasikan penilaian responden terhadap suatu layanan, sebagaimana diterapkan pada penelitian berbasis data mining yang memanfaatkan data hasil pengisian instrumen terstandar untuk proses analisis dan evaluasi model (Priyanto et al., 2024). Instrumen kuesioner yang digunakan terdiri dari sembilan variabel independen (X1–X9) yang merepresentasikan aspek fasilitas, kejelasan informasi akademik, keramahan petugas, kemudahan akses layanan daring, responsivitas layanan, efektivitas komunikasi, kecepatan administrasi, transparansi penilaian, serta ketersediaan sumber belajar. Penggunaan kuesioner berbasis skala Likert dalam mengukur kepuasan mahasiswa telah banyak diterapkan pada penelitian kepuasan layanan akademik di perguruan tinggi, seperti pada penelitian di STIKes Senior Medan dan Universitas Insan Pembangunan Indonesia, yang menekankan bahwa persepsi mahasiswa merupakan indikator utama kualitas layanan akademik.

Skala pengukuran pada Tabel 1 yang digunakan adalah skala Likert 1–5, di mana nilai 1 menunjukkan tingkat kepuasan sangat rendah dan nilai 5 menunjukkan tingkat kepuasan sangat tinggi. Penggunaan skala Likert dipilih karena mampu mengonversi persepsi subjektif responden menjadi data numerik yang terstruktur sehingga mudah diolah dalam analisis komputasional dan data mining. Skala Likert juga terbukti efektif digunakan sebagai nilai masukan dalam berbagai penelitian berbasis sistem pendukung keputusan dan klasifikasi, karena dapat meminimalkan ambiguitas penilaian serta menghindari permasalahan nilai nol pada proses pengolahan data (Dewi Antika, Syaiful Zuhri Harahap, Rahma Muti Ah, 2025). Dataset yang digunakan dalam penelitian ini terdiri dari 100 responden, yang selanjutnya digunakan sebagai data testing dalam proses evaluasi model klasifikasi, sejalan dengan



penelitian kepuasan berbasis kuesioner yang menyatakan bahwa jumlah responden minimal 100 sudah memenuhi kriteria representatif untuk analisis kuantitatif dan evaluasi model prediktif.

Tabel 1. Pengumpulan Data

NO	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
1	5	5	5	5	5	3	3	4	5	3
2	5	4	5	5	Null	4	5	5	4	3
3	Null	5	4	5	4	4	3	4	5	3
4	4	4	Null	4	3	5	5	5	3	2
5	3	3	5	4	2	5	5	4	5	2
6	2	5	3	4	5	3	Null	3	4	2
7	4	5	4	5	4	5	3	4	5	3
8	5	5	5	4	3	4	4	5	4	3
9	4	3	4	5	4	5	5	4	3	3
...	.	.	.	.	.	.	.	.	.	.
100	4	4	5	4	3	4	5	5	3	2

Data diolah menggunakan bahasa pemrograman Python dengan bantuan pustaka *pandas*, *numpy*, dan *scikit-learn*.

2.2 PREPROCESSING DATA

Tahap preprocessing dilakukan untuk memastikan dataset tidak mengandung nilai kosong (NULL) dan memiliki format yang konsisten. Pada tahap pengumpulan data, ditemukan bahwa beberapa responden tidak mengisi seluruh item kuesioner, sehingga menghasilkan nilai NULL pada beberapa atribut. Keberadaan nilai NULL dapat mempengaruhi kinerja algoritma klasifikasi, khususnya K-NN yang sangat bergantung pada perhitungan jarak antar data, serta Naïve Bayes yang membutuhkan data lengkap untuk menghitung probabilitas kelas (Saurina et al., 2022).

2.2.1 Penanganan Nilai NULL Menggunakan Mean

Dalam penelitian ini, nilai NULL pada atribut X1 sampai X9 ditangani menggunakan metode imputasi mean (nilai rata-rata) dari masing-masing atribut. Metode ini dipilih karena data berskala numerik dan bertujuan untuk mempertahankan seluruh data responden tanpa menghilangkan record yang tidak lengkap. Pendekatan imputasi mean banyak digunakan pada penelitian data mining dan analisis kepuasan mahasiswa karena mampu menjaga kestabilan distribusi data serta mendukung proses klasifikasi secara optimal (Ima. Hendro, 2022). Perhitungan nilai mean dilakukan menggunakan persamaan berikut:

$$\text{Mean} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

Keterangan :

x_i : nilai atribut ke-i

n : jumlah data yang tidak bernilai NULL

Metode mean dipilih karena data yang digunakan berskala numerik dan supaya data tetap bisa dianalisis tanpa merusak struktur dasar dataset.

2.2.2 Pembulatan Nilai Hasil Imputasi

Hasil imputasi mean menghasilkan beberapa nilai dalam bentuk desimal. Oleh karena itu, dilakukan proses **pembulatan nilai** untuk menjaga konsistensi skala Likert 1–5. Pembulatan nilai ini penting agar data tetap sesuai dengan konsep pengukuran kepuasan mahasiswa berbasis



persepsi ordinal (Sipahutar, 2022). Aturan pembulatan yang digunakan adalah nilai desimal $\geq 0,5$ dibulatkan ke atas dan nilai desimal $< 0,5$ dibulatkan ke bawah. Setelah tahap preprocessing selesai, diperoleh dataset yang lengkap, konsisten, dan siap digunakan dalam tahap pembangunan dan evaluasi model klasifikasi menggunakan algoritma **Naïve Bayes** dan **K-Nearest Neighbor (K-NN)**

2.2.3 Dataset Hasil Preprocessing

Setelah Dataset hasil preprocessing merupakan dataset akhir tanpa nilai NULL dan digunakan sebagai **data testing sebanyak 100 data responden**. Dataset ini digunakan untuk mengevaluasi performa model klasifikasi Naïve Bayes dan K-NN, sebagaimana diterapkan pada penelitian analisis sentimen yang membandingkan kedua algoritma dalam mengukur performa klasifikasi berdasarkan data numerik dan kategorikal (Sipahutar, 2022).

Tabel 2. Dataset Hasil Preprocessing Data

Responden	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
1	5	5	5	5	5	3	3	4	5	2
2	5	4	5	5	4	4	5	5	4	3
3	4	5	4	5	4	4	3	4	5	3
4	4	4	4	4	3	5	5	5	3	2
5	3	3	5	4	2	5	5	4	5	2
6	2	5	3	4	5	3	4	3	4	2
7	4	5	4	5	4	5	3	4	5	3
8	5	5	5	4	3	4	4	5	4	3
9	4	3	4	5	4	5	5	4	3	3
...	...	...	...	...	...	...	...	...	...	...
100	4	4	5	4	3	4	5	5	3	2

2.3 PEMBANGUNAN MODEL NAÏVE BAYES

Pada tahap ini, dataset hasil preprocessing yang telah bebas dari nilai NULL digunakan untuk membangun model klasifikasi menggunakan algoritma Naïve Bayes. Algoritma Naïve Bayes merupakan metode klasifikasi probabilistik yang didasarkan pada Teorema Bayes dengan asumsi bahwa setiap atribut bersifat saling independen (conditional independence). Pendekatan ini banyak digunakan pada penelitian klasifikasi data kuesioner karena mampu menyederhanakan proses perhitungan probabilitas tanpa mengurangi akurasi secara signifikan. Penggunaan Naïve Bayes dalam analisis kepuasan mahasiswa, menunjukkan bahwa algoritma ini efektif dalam mengklasifikasikan tingkat kepuasan mahasiswa berdasarkan data penilaian berbasis skala Likert (Sipahutar, 2022). Selain itu, algoritma Naïve Bayes juga membuktikan bahwa mampu memberikan hasil klasifikasi yang stabil pada data survei mahasiswa (Nasution et al., 2023). Secara umum, Teorema Bayes dinyatakan sebagai berikut :

$$P(C | X) = \frac{P(X|C) \cdot P(C)}{P(X)} \quad (2)$$

Keterangan :

- C : kelas kepuasan mahasiswa (Sangat Puas, Cukup Puas, Tidak Puas)
- X : vektor atribut ($X_1, X_2, \dots, X_9$)
- $P(C | X)$: probabilitas posterior
- $P(X | C)$: likelihood
- $P(C)$: probabilitas prior
- $P(X)$: probabilitas evidence



Karena nilai $P(X)$ bersifat konstan untuk setiap kelas, maka proses klasifikasi dilakukan dengan membandingkan nilai posterior terbesar:

$$P(C | X) \propto P(C) \prod_{i=1}^n P(X_i | C) \quad (3)$$

Kelas dengan nilai probabilitas terbesar dipilih sebagai hasil klasifikasi tingkat kepuasan mahasiswa.

2.3.1 Perhitungan Probabilitas Prior

Probabilitas prior merupakan peluang awal suatu kelas kepuasan mahasiswa yang ditentukan sebelum mempertimbangkan pengaruh atribut-atribut layanan akademik. Dalam konteks algoritma Naïve Bayes, probabilitas prior berfungsi untuk merepresentasikan proporsi kemunculan masing-masing kelas berdasarkan data historis pada variabel target (X_{10}). Perhitungan probabilitas prior dilakukan dengan melihat distribusi kelas kepuasan mahasiswa dalam keseluruhan dataset, sehingga mampu menggambarkan kecenderungan awal tingkat kepuasan mahasiswa terhadap layanan akademik di Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG). Pendekatan ini sejalan dengan konsep probabilitas Bayes yang menekankan bahwa informasi awal (prior knowledge) menjadi dasar penting dalam proses pengambilan keputusan berbasis probabilistik (Ainun Jariah, 2025).

Pendekatan probabilitas prior ini juga menjelaskan bahwa probabilitas awal kelas berperan penting dalam membentuk keputusan akhir model klasifikasi (Fauzia & Dana, 2023). Selain itu, hal ini menegaskan bahwa distribusi kelas awal dapat mencerminkan kecenderungan umum persepsi responden (Syahputra, Ryan. Bister, 2021). Secara matematis, probabilitas prior dirumuskan sebagai berikut :

$$P(C_k) = \frac{\text{Jumlah data dengan kelas } C_k}{\text{Jumlah seluruh data}} \quad (4)$$

Keterangan:

C_k : kelas kepuasan mahasiswa ke-k (misalnya Sangat Puas, Cukup Puas, Tidak Puas)

2.3.2 Perhitungan Likelihood (Gaussian Naive Bayes)

Likelihood menggambarkan peluang munculnya suatu nilai atribut tertentu ketika diketahui kelas kepuasan mahasiswa. Pada algoritma Naïve Bayes, perhitungan likelihood berfungsi untuk mengestimasi distribusi probabilitas setiap atribut terhadap masing-masing kelas berdasarkan data pelatihan. Dalam penelitian ini, atribut X_1 – X_9 berupa data numerik hasil kuesioner dengan skala Likert, sehingga pendekatan Gaussian Naïve Bayes digunakan karena mampu menangani atribut numerik yang diasumsikan mengikuti distribusi normal pada setiap kelas. Pendekatan ini umum diterapkan dalam proses klasifikasi data numerik dan terbukti efektif dalam mengukur probabilitas kemunculan suatu nilai atribut terhadap kelas tertentu (Putro et al., 2024)

Pendekatan Gaussian Naïve Bayes digunakan untuk menyatakan bahwa data penilaian mahasiswa cenderung mengikuti distribusi normal pada masing-masing kelas kepuasan (Syahputra, Ryan. Bister, 2021). Hal serupa juga menjelaskan di mana distribusi Gaussian dinilai sesuai untuk data numerik hasil kuesioner. Fungsi densitas probabilitas Gaussian dinyatakan sebagai berikut :

$$P(X_i | C_k) = \frac{1}{\sqrt{2\pi\sigma_{ik}^2}} \exp \left(-\frac{(x_i - \mu_{ik})^2}{2\sigma_{ik}^2} \right) \quad (5)$$

Keterangan :



Artikel ini didistribusikan mengikuti lisensi Atribusi-NonKomersial CC BY-NC sebagaimana tercantum pada <https://creativecommons.org/licenses/by-nc/4.0/>.

X_i : atribut ke- i (X_1 – X_9)
 x_i : nilai atribut ke- i pada data yang diklasifikasikan
 C_k : kelas kepuasan mahasiswa ke- k
 μ_{ik} : rata-rata atribut X_i pada kelas C_k
 σ_{ik}^2 : varians atribut X_i pada kelas C_k
 π : konstanta matematika ($\approx 3,14$)
 $\exp$: fungsi eksponensial

Nilai likelihood ini akan dikombinasikan dengan probabilitas prior untuk menghitung probabilitas posterior pada tahap penentuan kelas.

2.3.3 Keputusan Klasifikasi Naive Bayes

Tahap keputusan klasifikasi bertujuan untuk menentukan kelas kepuasan mahasiswa berdasarkan nilai probabilitas posterior terbesar. Probabilitas posterior diperoleh dari hasil perkalian antara probabilitas prior dan likelihood seluruh atribut X_1 – X_9 . Pendekatan penentuan kelas berdasarkan probabilitas maksimum ini menyimpulkan bahwa pemilihan kelas dengan probabilitas terbesar mampu merepresentasikan tingkat kepuasan responden secara objektif (Nasution et al., 2023).

$$\hat{C} = \arg \max_{C_k} [P(C_k) \prod_{i=1}^9 P(X_i | C_k)] \quad (6)$$

Keterangan:

$\hat{C}$: kelas kepuasan hasil prediksi
 $\arg \max$: operator untuk memilih nilai maksimum
 $P(C_k)$: probabilitas prior kelas C_k
 $P(X_i | C_k)$: likelihood atribut X_i pada kelas C_k
 Π : operator perkalian seluruh atribut X_1 hingga X_9

2.4 Pembangunan Model K-Nearest Neighbor (K-NN)

K-Nearest Neighbor (K-NN) merupakan algoritma klasifikasi berbasis jarak yang menentukan kelas suatu data berdasarkan kedekatan jarak dengan data latih. Algoritma ini banyak digunakan pada penelitian kepuasan mahasiswa karena mampu menangkap kemiripan karakteristik responden secara langsung. Pendekatan K-NN pada penelitian menyatakan bahwa pengukuran jarak antar responden dapat menggambarkan pola kepuasan yang serupa (Attamimi et al., 2022). Jarak antar data dihitung menggunakan Euclidean Distance sebagai berikut :

$$d(x, y) = \sqrt{\sum_{i=1}^9 (x_i - y_i)^2} \quad (7)$$

Keterangan :

$d(x, y)$: jarak antara data uji dan data latih
 $d(x, y)$: jarak antara data uji dan data latih
 x : vektor data uji
 y : vektor data latih
 x_i : nilai atribut ke- i pada data uji
 y_i : nilai atribut ke- i pada data latih
 i : indeks atribut (X_1 – X_9)

Nilai K ditentukan sebesar 3 untuk menghindari pengaruh noise dan menjaga keseimbangan antara bias dan varians, sebagaimana diterapkan pada beberapa penelitian klasifikasi kepuasan mahasiswa berbasis K-NN.



2.5 Evaluasi Model

Evaluasi model dilakukan untuk mengukur kemampuan algoritma Naïve Bayes dan K-NN dalam mengklasifikasikan tingkat kepuasan mahasiswa. Penggunaan metrik akurasi, presisi, recall, dan F1-score juga diterapkan untuk menilai performa model secara menyeluruh dari sisi ketepatan dan kemampuan deteksi kelas (Nasution et al., 2023).

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \quad (8)$$

Akurasi mengukur proporsi data yang diklasifikasikan dengan benar terhadap seluruh data

$$\text{Precision} = \frac{TP}{TP+FP} \quad (9)$$

Presisi mengukur tingkat ketepatan model dalam memprediksi suatu kelas.

$$\text{Recall} = \frac{TP}{TP+FN} \quad (10)$$

Recall mengukur kemampuan model dalam mendeteksi seluruh data yang benar pada suatu kelas.

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (11)$$

F1-score merupakan rata-rata harmonik antara presisi dan recall.

Keterangan:

TP (True Positive)	: data positif yang diprediksi benar
TN (True Negative)	: data negatif yang diprediksi benar
FP (False Positive)	: data negatif yang diprediksi positif
FN (False Negative)	: data positif yang diprediksi negative

Keempat metrik tersebut digunakan untuk memberikan gambaran menyeluruh terhadap performa model, baik dari sisi ketepatan prediksi maupun kemampuan model dalam mengenali seluruh data pada masing-masing kelas.

2.6 ANALISIS PERBANDINGAN MODEL

Analisis perbandingan model dilakukan untuk menentukan algoritma yang paling optimal dalam mengklasifikasikan tingkat kepuasan mahasiswa terhadap layanan akademik di IBIKKG. Dataset yang digunakan berjumlah 100 responden, dengan pembagian 70 data sebagai data latih dan 30 data sebagai data uji (testing). Pembagian data dengan rasio 70:30 dinilai mampu memberikan evaluasi performa model yang objektif terhadap data yang belum pernah dipelajari sebelumnya (Syahputra, Ryan. Bister, 2021).

3 HASIL DAN PEMBAHASAN

Pada tahapan ini akan menyajikan hasil implementasi dan pembahasan dari metode penelitian yang telah dijelaskan pada Bab II. Analisis difokuskan pada penerapan algoritma Naïve Bayes dan K-Nearest Neighbor (K-NN) dalam mengklasifikasikan tingkat kepuasan mahasiswa terhadap layanan akademik di Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG).



Pembahasan meliputi tahapan preprocessing data, pembangunan model klasifikasi, serta analisis hasil prediksi pada data uji. Evaluasi model tidak hanya dilakukan berdasarkan kinerja pada data training, tetapi juga difokuskan pada pola distribusi kelas hasil prediksi data uji, sehingga dapat memberikan gambaran yang lebih realistis terhadap kemampuan generalisasi masing-masing algoritma pada data yang belum pernah dilihat sebelumnya. Pendekatan evaluasi dan perbandingan algoritma klasifikasi ini sejalan dengan penelitian sebelumnya yang menerapkan Naïve Bayes dan K-Nearest Neighbor pada data survei dan data pendidikan (Susilo, 2023) (Novianto et al., 2023).

3.1 Deskripsi Dataset dan Tahap Preprocessing

Penelitian ini menggunakan dataset kepuasan mahasiswa terhadap layanan akademik Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG) yang diperoleh melalui kuesioner berbasis skala Likert. Dataset terdiri dari 100 data responden seperti yang ditunjukkan pada **Gambar 2**.

```
# =====  
# IMPORT LIBRARY  
# =====  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
  
from sklearn.naive_bayes import GaussianNB  
from sklearn.neighbors import KNeighborsClassifier  
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score  
  
# =====  
# DATA TRAINING  
# =====  
columns_train = ["X" + str(i) for i in range(1,11)]  
data_train = [  
    [5,5,5,5,3,3,4,5,2],  
    [5,5,4,4,5,4,5,5,3],  
    [3,2,3,4,3,2,3,4,4,2],  
    [5,5,5,5,5,5,5,5,3],  
    [3,3,4,3,3,4,4,4,2],  
    [4,5,4,4,5,4,4,4,3,2],  
    [4,5,4,5,5,3,4,5,3],  
    [4,4,4,4,4,4,4,4,2],  
    [3,5,4,5,3,3,4,5,2],  
    [5,4,4,5,4,4,5,4,2],  
    [3,2,4,4,3,3,4,3,2,2],  
    [4,4,5,5,4,5,5,5,4,3],  
    [4,5,3,4,2,3,5,5,4,2],  
    [4,4,4,4,4,4,4,4,2],  
    [4,4,4,4,4,4,4,4,3],  
    [4,4,5,5,5,5,5,5,3,2],  
    [5,5,5,5,5,4,5,5,5,3],  
    [4,3,4,4,4,5,5,4,4,2],  
    [3,3,5,5,4,5,5,4,2,2],  
    [4,5,5,5,4,5,5,5,4,3],  
    [4,4,3,5,4,4,5,5,3,2],  
    [3,4,4,4,4,4,4,4,3,2],  
    [5,4,4,5,4,4,4,3,3,2],  
    [4,4,4,4,3,5,4,4,2],  
    [5,5,5,5,5,5,5,5,3],  
    [4,4,5,4,5,3,5,2],  
    [4,4,5,4,5,3,5,2],  
    [5,5,4,3,3,4,5,5,2],  
    [5,5,4,4,4,4,4,4,3],  
    [5,5,5,4,4,4,3,3,3],  
    [5,5,5,4,4,4,4,4,3],  
    [5,5,4,4,4,3,3,3,3],  
    [3,3,3,4,4,4,5,5,2],  
    [4,4,4,3,3,4,4,5,3],  
    [5,5,4,4,3,3,2,2,5,2],  
    [4,4,4,5,5,4,3,5,4,3],  
    [4,4,4,4,4,4,4,4,4,3],  
    [4,4,4,4,4,4,4,4,3],  
    [5,5,5,5,5,5,5,5,3],  
    [5,4,3,5,4,3,5,4,3,3],  
    [3,3,3,4,4,4,5,5,2],  
    [4,4,4,4,4,4,4,4,2],  
    [3,3,3,3,3,3,3,4,3,2],  
    [3,3,3,5,4,4,4,4,4,2],  
    [4,4,4,4,4,4,4,4,2]  
]
```

Gambar 2. Memasukkan Data Training

Setiap data memiliki **sembilan atribut input (X1–X9)** yang merepresentasikan aspek layanan akademik, serta **satu variabel kelas (X10)** yang menunjukkan tingkat kepuasan mahasiswa dengan tiga kategori, yaitu **Tidak Puas (1)**, **Cukup Puas (2)**, dan **Sangat Puas (3)**.

Tahap preprocessing dilakukan untuk memastikan data berada dalam kondisi lengkap dan konsisten sebelum digunakan dalam proses pembelajaran model. Penanganan data kosong dan penyesuaian skala Likert merupakan langkah penting dalam penelitian berbasis kepuasan mahasiswa, sebagaimana dilakukan pada penelitian sebelumnya (Kartini & Sanmorino, 2024).

3.2 Pembangunan Model Naïve Bayes dan KNN

Tahap pembangunan model diawali dengan memuat data ke dalam struktur *DataFrame*, kemudian memisahkan atribut input (X1–X9) dan variabel kelas (X10). Selanjutnya, dataset dibagi menjadi **data training** dan **data uji**. Data training digunakan untuk melatih model, sedangkan data uji digunakan untuk mengevaluasi kemampuan prediksi model terhadap data yang belum pernah dipelajari.



Pemilihan algoritma Naïve Bayes dan K-Nearest Neighbor (K-NN) didasarkan pada kemampuannya dalam menangani data numerik dan skala Likert, serta sering digunakan dalam penelitian klasifikasi berbasis data survei dan kepuasan pengguna (Susilo, 2023).

Proses pembangunan model Naïve Bayes dan K-NN menggunakan bahasa pemrograman Python ditunjukkan pada **Gambar 3**.

```
# ----- Naïve Bayes -----
nb_model = GaussianNB()
nb_model.fit(X_train, y_train)
y_pred_test_nb = nb_model.predict(df_test)

# ----- K-Nearest Neighbor -----
knn_model = KNeighborsClassifier(n_neighbors=3)
knn_model.fit(X_train, y_train)
y_pred_test_knn = knn_model.predict(df_test)
```

Gambar 3. Pembangunan Model Naïve Bayes dan KNN

3.3 Hasil dan Pembahasan Model Naïve Bayes

Model Naïve Bayes dibangun menggunakan pendekatan **Gaussian Naïve Bayes**, karena data bersifat numerik dan berasal dari skala Likert. Model dilatih menggunakan data training yang telah melalui tahap preprocessing.

Setelah proses pelatihan, model digunakan untuk melakukan prediksi pada **data uji**. Proses menampilkan hasil prediksi data uji oleh model Naïve Bayes ditampilkan pada **Gambar 4**, sedangkan ringkasan output prediksi ditunjukkan pada **Gambar 5**.

```
# Hasil Naïve Bayes
hasil_nb = df_test.copy()
hasil_nb['Prediksi_X10'] = y_pred_test_nb

print("=== HASIL PREDIKSI DATA UJI (NAÏVE BAYES) ===")
print(hasil_nb)
```

Gambar 4. Proses menampilkan hasil prediksi data uji dengan model Naïve Bayes



```

***  === HASIL PREDIKSI DATA UJI (NAÏVE BAYES) ===
      X1  X2  X3  X4  X5  X6  X7  X8  X9  Prediksi_X10
0      1   1   2   3   1   2   1   1   2           1
1      1   1   2   4   1   1   1   2   1           1
2      4   4   1   4   1   3   4   1   2           2
3      4   5   4   4   3   5   4   5   4           2
4      1   1   1   3   2   1   1   1   3           1
5      4   4   4   2   3   5   3   5   5           2
6      3   1   1   4   2   1   5   2   5           1
7      3   2   1   5   1   5   1   1   1           2
8      1   4   1   2   3   3   5   4   3           2
9      2   1   1   2   2   1   1   2   2           1
10     1   5   3   2   2   4   2   2   5           2
11     4   1   4   2   3   2   3   2   3           1
12     5   4   4   4   4   5   4   5   4           3
13     3   5   2   2   3   2   5   4   5           2
14     1   1   3   4   1   2   2   5   5           2
15     5   5   4   4   5   4   5   4   5           3
16     1   3   3   3   1   3   3   3   3           2
17     4   1   2   4   1   3   4   4   4           2
18     4   1   4   1   1   5   2   3   4           2
19     4   2   3   1   3   5   5   4   3           2
20     3   1   5   1   3   2   2   4   4           1
21     1   5   2   5   2   3   3   2   5           2
22     3   5   5   5   5   4   5   5   5           3
23     5   4   5   4   5   5   4   5   4           3
24     3   1   3   3   3   2   4   4   3           2
25     4   2   4   3   4   2   3   4   4           2
26     4   2   1   5   3   4   3   4   4           2
27     3   3   3   1   3   4   3   4   3           2
28     3   2   3   1   4   4   2   3   4           2
29     4   1   4   2   3   4   2   5   4           2

```

Gambar 5. Hasil prediksi data uji model naïve bayes

Hasil prediksi data uji ditampilkan pada **Gambar 5** yang memperlihatkan keseluruhan data uji beserta nilai prediksi yang dihasilkan oleh model. Pada gambar tersebut, setiap baris merepresentasikan satu data responden dengan variabel X1 hingga X10 sebagai atribut input, sedangkan kolom **Prediksi_X10** menunjukkan hasil klasifikasi yang diberikan oleh model Naïve Bayes. Nilai pada kolom prediksi menunjukkan kelas yang diperkirakan oleh model berdasarkan pola probabilitas yang dipelajari selama proses training. Dengan adanya tampilan ini, dapat diamati secara langsung bagaimana model memberikan keputusan klasifikasi terhadap masing-masing data uji.

```


Naïve Bayes:
2    63.33
1    23.33
3    13.33
Name: proportion, dtype: float64

```

Gambar 6. Hasil/Output model naïve bayes

Selanjutnya, ringkasan hasil prediksi ditampilkan pada **Gambar 6**, yang menyajikan distribusi atau proporsi hasil klasifikasi dari model Naïve Bayes. Berdasarkan output pada **Gambar 6**, diperoleh bahwa **Kelas 2** memiliki proporsi sebesar **63,33%**, **Kelas 1** memiliki proporsi **23,33%**, sedangkan **Kelas 3** dengan proporsi **13,33%**. Hasil ini memberikan gambaran umum mengenai kecenderungan hasil prediksi model, misalnya dominasi kelas tertentu dibandingkan kelas lainnya. Output ringkasan ini disajikan dalam bentuk **Naïve Bayes proportion dengan tipe data float64**, yang menunjukkan nilai probabilitas atau proporsi numerik dari masing-masing kelas hasil prediksi. Nilai bertipe float64 menandakan bahwa hasil yang ditampilkan merupakan nilai desimal dengan presisi tinggi, sehingga mampu merepresentasikan probabilitas secara lebih akurat. Untuk memperoleh gambaran yang lebih jelas mengenai kecenderungan prediksi, dilakukan visualisasi **distribusi kelas hasil prediksi data uji**, sebagaimana ditunjukkan pada **Gambar 7**.





Gambar 7. Grafik distribusi model Naïve Bayes

Berdasarkan grafik distribusi **Gambar 7**, terlihat bahwa model Naïve Bayes menunjukkan hasil proporsi **Kelas 2** (cukup puas) sebanyak **63,33%**, **Kelas 1** (sangat tidak puas) memiliki proporsi **23,33%**, sedangkan **Kelas 3** (sangat puas) memiliki proporsi **13,33%**. Hal ini mencerminkan karakteristik pendekatan probabilistik Naïve Bayes yang mengandalkan distribusi global data training. Sehingga hasil distribusi model Naïve Bayes terdistribusi secara optimal.

3.4 Hasil dan Pembahasan Model K-Nearest Neighbor (K-NN)

Sebagai metode pembandingan, penelitian ini menggunakan algoritma **K-Nearest Neighbor (K-NN)** dengan nilai **K = 3** dan **jarak Euclidean** sebagai ukuran kedekatan antar data. Model K-NN melakukan klasifikasi berdasarkan tingkat kemiripan data uji terhadap data latih pada atribut X1 hingga X9 yang merepresentasikan karakteristik responden.

Proses menampilkan hasil prediksi data uji menggunakan model K-NN ditampilkan pada **Gambar 8**, dengan output prediksi yang dirangkum pada **Gambar 9**.

```
# Hasil K-NN
hasil_knn = df_test.copy()
hasil_knn['Prediksi_X10'] = y_pred_test_knn

print("\n=== HASIL PREDIKSI DATA UJI (K-NN) ===")
print(hasil_knn)
```

Gambar 8. Menampilkan hasil data uji dengan model K-NN



```

=== HASIL PREDIKSI DATA UJI (K-NN) ===

```

	X1	X2	X3	X4	X5	X6	X7	X8	X9	Prediksi_X10
0	1	1	2	3	1	2	1	1	2	2
1	1	1	2	4	1	1	1	2	1	2
2	4	4	1	4	1	3	4	1	2	2
3	4	5	4	4	3	5	4	5	4	2
4	1	1	1	3	2	1	1	1	3	2
5	4	4	4	2	3	5	3	5	5	2
6	3	1	1	4	2	1	5	2	5	2
7	3	2	1	5	1	5	1	1	1	2
8	1	4	1	2	3	3	5	4	3	2
9	2	1	1	2	2	1	1	2	2	2
10	1	5	3	2	2	4	2	2	5	2
11	4	1	4	2	3	2	3	2	3	2
12	5	4	4	4	4	5	4	5	4	3
13	3	5	2	2	3	2	5	4	5	2
14	1	1	3	4	1	2	2	5	5	2
15	5	5	4	4	5	4	5	4	5	3
16	1	3	3	3	1	3	3	3	3	2
17	4	1	2	4	1	3	4	4	4	2
18	4	1	4	1	1	5	2	3	4	2
19	4	2	3	1	3	5	5	4	3	2
20	3	1	5	1	3	2	2	4	4	2
21	1	5	2	5	2	3	3	2	5	2
22	3	5	5	5	5	4	5	5	5	3
23	5	4	5	4	5	5	4	5	4	3
24	3	1	3	3	3	2	4	4	3	2
25	4	2	4	3	4	2	3	4	4	2
26	4	2	1	5	3	4	3	4	4	2
27	3	3	3	1	3	4	3	4	3	2
28	3	2	3	1	4	4	2	3	4	2
29	4	1	4	2	3	4	2	5	4	2

Gambar 9. Hasil prediksi data uji K-NN

Hasil prediksi yang diperoleh menunjukkan bahwa model K-NN mampu mengelompokkan data uji ke dalam kelas tertentu berdasarkan kesamaan pola nilai atribut. Dengan pendekatan berbasis kedekatan data, model ini tidak memerlukan proses pelatihan yang kompleks, namun sangat bergantung pada distribusi dan kualitas data latih.

Ringkasan hasil prediksi model K-NN ditampilkan pada **Gambar 10**, yang menyajikan **proporsi hasil klasifikasi** dalam bentuk nilai numerik bertipe **float64**. Berdasarkan output tersebut, diperoleh bahwa **kelas 2** memiliki proporsi sebesar **86,67%** sedangkan **Kelas 3** memiliki proporsi sebesar **13,33%**. Proporsi ini menunjukkan bahwa sebagian besar data uji diklasifikasikan ke dalam kelas 2 oleh model K-NN. Dominasi kelas tertentu mengindikasikan adanya pola karakteristik responden yang lebih dekat dengan kelas tersebut berdasarkan atribut X1–X9. Secara keseluruhan, hasil ini menunjukkan bahwa model K-NN mampu melakukan klasifikasi data uji dengan distribusi prediksi yang cukup jelas. Nilai proporsi bertipe float64 menggambarkan tingkat presisi model dalam merepresentasikan hasil klasifikasi secara numerik, sehingga dapat digunakan sebagai dasar untuk tahap evaluasi performa model lebih lanjut dan perbandingan dengan metode Naïve Bayes

```


K-NN:
2    86.67
3    13.33
Name: proportion, dtype: float64

```

Gambar 10. Hasil/Output model KNN

Distribusi kelas hasil prediksi data uji oleh model K-NN divisualisasikan pada **Gambar 11**.





Gambar 11. Output Grafik distribusi model K-NN

Berdasarkan grafik **Gambar 11**, pendekatan berbasis jarak menghasilkan klasifikasi proporsi **Kelas 2** (cukup puas) sebanyak **86.67%** dan proporsi **Kelas 3** (sangat puas) sebanyak **13,33%**. K-NN menangkap kemiripan lokal antar responden, namun kelemahannya adalah data yang menyimpang dapat memengaruhi hasil klasifikasi karena KNN mengandalkan kedekatan jarak antar data. Sehingga hasil distribusi model K-NN tidak terdistribusi secara optimal.

3.5 Analisis Perbandingan Model

Analisis perbandingan model dilakukan berdasarkan **hasil prediksi data uji**, dengan fokus pada **distribusi kelas** dan **kecenderungan prediksi** masing-masing algoritma. Proses menampilkan perbandingan distribusi prediksi Naïve Bayes dan K-NN ditunjukkan pada **Gambar 11**.

```
konsistensi = np.mean(y_pred_test_nb == y_pred_test_knn) * 100
```

Gambar 11. Menampilkan perbandingan distribusi kedua model

Gambar 12 menunjukkan output perbandingan kedua model di rangkum yaitu Naïve Bayes dan K-NN.

```
=== DISTRIBUSI KELAS HASIL PREDIKSI DATA UJI (%) ===


Naïve Bayes:
2    63.33
1    23.33
3    13.33
Name: proportion, dtype: float64

K-NN:
2    86.67
3    13.33
Name: proportion, dtype: float64

Tingkat Konsistensi Prediksi Naïve Bayes dan K-NN: 76.67%
```

Gambar 12. Distribusi kelas dari kedua model





Gambar 13. Perbandingan Prediksi Data Uji

Berdasarkan visualisasi **Gambar 13**, terlihat bahwa model K-NN menghasilkan distribusi prediksi yang lebih seimbang antar kelas dibandingkan Naïve Bayes. Hal ini menunjukkan bahwa K-NN memiliki kemampuan yang lebih baik dalam menangkap variasi karakteristik responden pada data uji. Pendekatan berbasis jarak yang digunakan oleh K-NN memungkinkan proses klasifikasi mempertimbangkan kedekatan antar data secara langsung, sehingga lebih adaptif dalam mengelompokkan data dengan karakteristik yang mirip (Novianto et al., 2023).

Sebaliknya, model Naïve Bayes menunjukkan kecenderungan prediksi yang lebih terpusat pada kelas tertentu. Kondisi ini berkaitan dengan asumsi independensi antar atribut yang digunakan oleh algoritma Naïve Bayes, sehingga hubungan antar variabel input tidak sepenuhnya dapat dimodelkan. Performa Naïve Bayes dapat menurun ketika atribut-atribut input memiliki keterkaitan atau korelasi yang cukup kuat (Al Arif et al., 2022). Dengan demikian, berdasarkan analisis hasil prediksi data uji dan distribusi kelas, algoritma **K-Nearest Neighbor (K-NN)** dinilai lebih sesuai untuk digunakan dalam mengklasifikasikan tingkat kepuasan mahasiswa terhadap layanan akademik di IBIKKG pada dataset penelitian ini.

4. KESIMPULAN

Penelitian ini bertujuan untuk mengklasifikasikan tingkat kepuasan mahasiswa terhadap layanan akademik di Institut Bisnis dan Informatika Kwik Kian Gie (IBIKKG) menggunakan algoritma Naïve Bayes dan K-Nearest Neighbor (K-NN). Berdasarkan hasil implementasi dan analisis, dapat disimpulkan bahwa kedua algoritma berhasil membangun model klasifikasi dan menghasilkan prediksi tingkat kepuasan mahasiswa pada data uji yang belum memiliki label kelas. Model Naïve Bayes menunjukkan kecenderungan prediksi yang terdistribusi secara optimal terhadap karakteristik data survei berbasis skala Likert.

Sementara itu, algoritma K-Nearest Neighbor (K-NN) menghasilkan distribusi prediksi yang tidak terdistribusi secara optimal terhadap karakteristik data survei berbasis skala Likert. Berdasarkan uji coba yang telah dilakukan. Namun kedua algoritma tersebut mampu memberikan hasil klasifikasi prediksi dengan Tingkat Konsistensi Prediksi sebesar 76,67%.

Dengan demikian, berdasarkan analisis distribusi hasil prediksi data uji dan perbandingan karakteristik kedua model, algoritma Naïve Bayes dinilai lebih sesuai digunakan untuk mengklasifikasikan tingkat kepuasan mahasiswa terhadap layanan akademik di IBIKKG pada dataset penelitian ini.



DAFTAR PUSTAKA

- Ainun Jariah, H. M. (2025). Penerapan Probabilitas Bayes dalam Pengambilan Keputusan Akademik Siswa. *Jurnal Ilmu Sosial, Politik, Dan Hukum*, 2(3), 28–40.
- Al Arif, A., Firdaus, M., Rahmadden, & Maruhawa, Y. (2022). Perbandingan Metode Data Mining untuk Prediksi Curah Hujan dengan Algoritma C4.5, Naïve Bayes, dan KNN. In *SENTIMAS : Seminar Nasional Penelitian dan Pengabdian Masyarakat*.
- Anhikmah, T. P. (2025). Pengaruh Komunikasi Digital, Kepuasan Mahasiswa, Inovasi, Kolaborasi Digital Terhadap Reputasi Organisasi di Universitas Mbojo Bima. *Pengaruh Komunikasi Digital, Kepuasan Mahasiswa, Inovasi, Kolaborasi Digital Terhadap Reputasi Organisasi Di Universitas Mbojo Bima*, 5(6).
- Attamimi, Y., W.Tuhumena, C., & Syauta, J. H. (2022). ANALISIS KEPUASAN MAHASISWA TERHADAP PELAYANAN AKADEMIK MELALUI PORTAL AKADEMIK UNIVERSITAS CENDERAWASIH PADA MASA PANDEMI COVID-19. *JUMABIS (JURNAL MANAJEMEN & BISNIS)*, 6(November), 104–118.
- Butarbutar, F., Susiyanto, H., Layanan, T., Dengan, A., Servqual, M., Qfd, D. A. N., Kasus, S., Methods, Q. F. D., & Study, C. (2021). *AKADEMIK DENGAN PENDEKATAN METODE SERVQUAL DAN QFD (Studi Kasus Fakultas Teknik Universitas Krisnadwipayana)*. 24(2), 0–7.
- Dewi Antika, Syaiful Zuhri Harahap, Rahma Muti Ah, A. P. J. (2025). Penerapan Data mining Klasifikasi Tingkat Kepuasan Mahasiswa Terhadap Pelayanan Akademik Menggunakan Metode Naïve Bayes Dan Support Vector Machine. *Journal of Computer Science and Information Systems (JColnS)*, 6, 221–232.
- Fauzi, A. M. N., Triayudi, A., & Sholihati, I. D. (2022). Mengukur tingkat kepuasan pengguna aplikasi kearsipan menggunakan system usability scale dan pieces framework. *JUPI (Jurnal Ilmiah Penelitian Dan Pembelajaran Informatika)*, 07(01), 231–239.
- Fauzia, N. S., & Dana, R. D. (2023). Implementasi Algoritma Naive bayes dalam Klasifikasi Status Kesejahteraan Masyarakat Desa Gunungsari. *Jurnal Teknik*, 1–5.
- Ima. Hendro, D. A. (2022). ANALISA KEPUASAN MAHASISWA TERHADAP E-LEARNING MENGGUNAKAN ALGORITMA SUPPORT VECTOR MACHINE. *Saintek Maritim*, 23(September), 97–108.
- Kahar Muhammad Syahrul , Anwar Zakiyah Anwar Zakiyah, D. K. M. (2023). Jenis-Jenis Penelitian Dalam Penelitian Kuantitatif dan Kualitatif. *Jurnal Program Studi Fisika Indonesia*, 1(1), 279–295.
- Kartini, A., & Sanmorino, A. (2024). *ANALISIS TINGKAT KEPUASAN MAHASISWA TERHADAP SISTEM INFORMASI AKADEMIK STEBIS IGM MENGGUNAKAN METODE PIECES FRAMEWORK* (Vol. 2, Issue 1).
- Kenia, S., Loka, P., & Marsal, A. (2023). Perbandingan Algoritma K-Nearest Neighbor dan Naïve Bayes Classifier Untuk Klasifikasi Status Gizi Pada Balita. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 3(April), 8–14.
- Nasution, D. K., Novita, A., & Hafiz, M. S. (2023). Penilaian Implementasi Kegiatan Merdeka Belajar Kampus Merdeka Program Asistensi Mengajar Di Universitas Muhammadiyah Sumatera Utara. *Jurnal EduTech*, 9(1), 1–10.
- Natalia Nurtiani, D., & Adi Saputra, R. (2024). *KLASIFIKASI TINGKAT KEPUASAN MAHASISWA TERHADAP FASILITAS KAMPUS MENGGUNAKAN METODE ID3*. 8(1), 123–128. <https://doi.org/10.46880/jmika.Vol8No1.pp123-128>
- Novianto, E., Hermawan, A., & Avianto, D. (2023). KLASIFIKASI ALGORITMA K-NEAREST NEIGHBOR, NAIVE BAYES, DECISION TREE UNTUK PREDIKSI STATUS KELULUSAN MAHASISWA S1. *Rabit : Jurnal Teknologi Dan Sistem Informasi Univrab*, 8(2), 146–154. <https://doi.org/10.36341/rabit.v8i2.3434>
- Priyanto, I., Dewanti, E. M., Tundo, T., Nurdin, M., & Kasiono, R. (2024). Penerapan Algoritma Metode Naïve Bayes Untuk Penentuan Penerimaan Bantuan Program Indonesia Pintar (Pip). *Jurnal Manajemen Informatika Jakarta*, 4(2), 162. <https://doi.org/10.52362/jmijayakarta.v4i2.1355>
- Putro, Y. N. R., Afriansyah, A., & Bagaskara, R. (2024). Penggunaan Algoritma Gaussian Naïve Bayes & Decision Tree Untuk Klasifikasi Tingkat Kemenangan Pada Game Mobile Legends.



- JUKI : Jurnal Komputer Dan Informatika*, 6(1), 10–26. <https://doi.org/10.53842/juki.v6i1.472>
- Saurina, N., Rahayuningsih, T., & Retnawati, L. (2022). *Analisis Sentimen Ulasan Pelanggan Batik Ecoprint Menggunakan Naïve Bayes Dan KNN Classifier*. 9(2).
- Sipahutar, D. M. (2022). *ANALISIS TINGKAT KEPUASAN MAHASISWA TERHADAP PELAYANAN AKADEMIK DI STIKES SENIOR MEDAN*. 7(2).
- Susilo, A. (2023). Perbandingan Kinerja K-Nearest Neighbors dan Naive Bayes Untuk Klasifikasi Perilaku Nasabah Pada Pembayaran Kredit Bank. *Jurnal Sains Dan Teknologi (JSIT)*, 3(2), 153–169. <https://doi.org/10.47233/jsit.v3i3.1264>
- Syahputra, Ryan. Bister, P. (2021). Implementasi metode Naive Bayes Classifier pada Evaluasi Kepuasan Mahasiswa terhadap Pembelajaran Daring. *Jurnal Nasional Informatika Dan Teknologi Jaringan ISSN*, 6, 1–3.

